

An Overview of Maximal Update Parametrization (μP)

郑晨宇






内容纲要


- μP 的背景与影响
- 宽度扩展的 μP 理论与实践
- 宽深联合扩展的 μP 理论与实践
- 总结与展望

1.1 μP 的实际背景——大模型训练优化难

特征学习能力在无穷宽深时失效




大模型训练超参数搜索开销大、迁移难



1.2 μ P 的理论背景——深度学习理论发展的必经之路

- 传统深度学习理论：kernel regime（特征冻结）
 - Random feature model、Neural tangent kernel 等
- 新兴深度学习理论：feature learning regime（特征可学）
 - 无穷宽/深极限时的行为： μ P/Tensor Program/DMFT/Mean-field theory/...






1.3 μ P 的实际影响

- μ P 已经作为一种**准则**，被应用于前沿工业界的大模型**预训练**
 - 发明人 Greg Yang 为 xAI co-founder, μ P 被用于 Grok 全系列模型训练
 - μ P 原始算法论文与 OpenAI 合作训练 GPT-3, GPT 后续系列也使用了 μ P
 - DeepMind 发表多篇 μ P 相关的前沿探索文章, 也非常重视该类技术
 - Meta 的 Llama-4 报告中也明确提到利用了类似 μ P 的 “MetaP”


1.3 μ P 的实际影响

- μ P 能够**原则上保证**规模扩展时的特征学习稳定性






1.3 μ P 的实际影响

- μ P 能够**经验上指导**超参数在规模扩展时的迁移律



1.3 μP 的实际影响

- μP 能够有助于公平比较不同方法在大规模场景下的优劣





内容纲要

- $\mu\mathbf{P}$ 的背景与影响
- 宽度扩展的 $\mu\mathbf{P}$ 理论与实践
- 宽深联合扩展的 $\mu\mathbf{P}$ 理论与实践
- 总结与展望

2.1 μ P 的原则——最大稳定更新（又稳又快）

- μ P 原则上希望在特征变动量级和网络规模无关（稳定）的前提下尽可能更新权重（高效）。否则，特征随网络变大趋于爆炸或者冻结。

设 $h_l \in R^{n_l}$ 为第 l 层的特征， $\Delta h_l \in R^{n_l}$ 为其经过一步优化的更新量， μ P 希望：

$$\|h_l\|_{RMS} = \Theta(1), \|\Delta h_l\|_{RMS} = \Theta(1), \quad l \in [L]$$

$$\text{maximize } \Delta W'_l \text{'s contribution to } \Delta h_L, \quad l \in [L]$$

其中 $\|v\|_{RMS} = \frac{\|v\|_2}{\sqrt{d}} = \sqrt{\frac{\sum v_i^2}{d}}$ ，衡量是特征向量每个维度的平均大小。

2.2 宽度扩展 μP 的谱条件理论——原型与结果

- **最简理论原型**：能反映实际情况（如 Transformer）的最简单分析对象
 - 有限层 linear MLP ($h_l = W_l h_{l-1}$)，一步梯度下降，batch size 为 1
- 为了满足宽度扩展时的 μP 原则，可令**权重及其变化**满足以下条件

设 $W_l \in R^{n_l \times n_{l-1}}$ 为第 l 层的权重， $\Delta W_l \in R^{n_l \times n_{l-1}}$ 为其经过一步优化的变动，需要：

$$\|W_l\|_{RMS} = \Theta(1), \|\Delta W_l\|_{RMS} = \Theta(1), l \in [L]$$

$$\text{其中 } \|W\|_{RMS} = \sup_{x \neq 0} \frac{\|Wx\|_{RMS}}{\|x\|_{RMS}} = \sqrt{\frac{n_{l-1}}{n_l}} \|W\|_2。$$

2.2 宽度扩展 μP 的谱条件理论——核心推导

- $\|W_l\|_{RMS} = \Theta(1)$ 的推导：宽度足够大、高斯初始化是紧的

$$\begin{aligned}\|h_l\|_{RMS} &= \|W_l h_{l-1}\|_{RMS} \leq \|W_l\|_{RMS} \|h_{l-1}\|_{RMS} = \Theta(1) \\ \|h_{l-1}\|_{RMS} &= \Theta(1) \Rightarrow \|W_l\|_{RMS} = \Theta(1)\end{aligned}$$

- $\|\Delta W_l\|_{RMS} = \Theta(1)$ 的推导：一步更新、bs 为 1 是紧的

$$\begin{aligned}\|\Delta h_l\|_{RMS} &= \|\Delta W_l h_{l-1} + \Delta W_l \Delta h_{l-1} + W_l \Delta h_{l-1}\|_{RMS} \\ &\leq \|\Delta W_l\|_{RMS} (\|h_{l-1}\|_{RMS} + \|\Delta h_{l-1}\|_{RMS}) + \|W_l\|_{RMS} \|\Delta h_{l-1}\|_{RMS} = \Theta(1) \\ \|h_{l-1}\|_{RMS}, \|\Delta h_{l-1}\|_{RMS} &= \Theta(1) \Rightarrow \|\Delta W_l\|_{RMS} = \Theta(1)\end{aligned}$$

注： μP 原则上想最大化的是权重更新带来的特征变化

2.2 宽度扩展 μP 的谱条件理论——Adam 实现

- $\|W_l\|_{RMS} = \Theta(1)$ 可以由适当的高斯初始化得到, $W_l \sim N(0, \sigma_l^2)$

$$\sigma_l = \Theta\left(\frac{1}{\sqrt{n_{l-1}}} \min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$$

- $\|\Delta W_l\|_{RMS} = \Theta(1)$ 可以通过随宽度缩放学习率得到, 如对于Adam 有

$$\|\Delta W_l\|_2 \approx \eta_l \|\text{sign}(G_l)\|_2 \approx \eta_l \|\text{sign}(G_l)\|_F = \Theta\left(\sqrt{\frac{n_l}{n_{l-1}}}\right)$$
$$\|\text{sign}(G_l)\|_F = \sqrt{n_{l-1}n_l} \Rightarrow \eta_l = \Theta\left(\frac{1}{n_{l-1}}\right)$$

2.2 宽度扩展 μP 的谱条件理论——启发 Muon 优化器

- $\|W_l\|_{RMS} = \Theta(1)$ 可以由适当的高斯初始化得到, $W_l \sim N(0, \sigma_l^2)$

$$\sigma_l = \Theta\left(\frac{1}{\sqrt{n_{l-1}}} \min\left(1, \sqrt{\frac{n_l}{n_{l-1}}}\right)\right)$$

- $\|\Delta W_l\|_{RMS} = \Theta(1)$ 直接启发了 Muon 的设计（不用随宽度做学习率调整）

$$\begin{aligned}\|\Delta W_l\|_2 &= \eta_l \|UV^\top\|_2 = \eta_l = \Theta\left(\sqrt{\frac{n_l}{n_{l-1}}}\right) = \Theta(1) \\ \Rightarrow \eta_l &= \Theta(1) \text{ (hidden weights)}\end{aligned}$$


2.3 宽度扩展 μP 的实现——以 Adam 为例

- 在 base model 上用 SP 搜索最好的超参，比如学习率 η_{base}
- 在 target model 上，使用 μP 规律缩放超参，如使用 $\eta_{base}/r_n = \Theta(1/n)$
 - r_n 为 target model 与 base model 的宽度比值，如 2048/256

	Input weights & bias	Hidden weights	Output weights
Block Multiplier	α_{base}	(α_{base})	α_{base}/r_n (α_{base})
Initial Variance	σ_{base}^2/d_0 or σ_{base}^2	σ_{base}^2/r_n	σ_{base}^2 (σ_{base}^2/r_n)
Learning Rate	η_{base}	η_{base}/r_n (η_{base})	η_{base}
Weight Decay	λ_{base}	$\lambda_{base} r_n$ (λ_{base})	λ_{base}


2.3 宽度扩展 μ P 的实现——稳定训练

- μ P 从理论上保证了不同层特征的稳定更新，从而支持大模型稳定训练



2.3 宽度扩展 μP 的实现——超参迁移律/超参缩放律

- μP 参数化下的最优 base 超参数随着网络宽度增大而稳定迁移
- 直觉：如果不用这个迁移律，则特征在极限情况趋向退化/爆炸，非最优





2.4 宽度扩展 μP 的 Tensor Program 理论——对象与结果

- Tensor Program 将 toy model 的 μP 结论严格推广到一般的无穷宽网络训练
 - 一般的架构：包括 MLP、CNN、Transformer 等
 - 一般的 element-wise adaptive optimizer：包括 SGD、Adam 等
 - 训练步数为 $\Theta(1)$ ，且训练没收敛
 - 数据维度为 $\Theta(1)$ ，RMS 范数为 $\Theta(1)$
- 在上述条件下， μP 结论与谱范数理论结果一致



2.4 宽度扩展 μ P 的 Tensor Program 理论——架构范畴

- Tensor Program 的网络权重初始化要求：高斯初始化
 - 也可以拓展到一般的零均值、矩有界的分布

Setup 2.6.3 (Gaussian). Assume¹⁴

1. Every entry of every $W \in \mathcal{W}$ is sampled iid from $\mathcal{N}(0, 1/n)$.
2. Every entry of every initial vector $x \in \mathbf{x}^0$ is sampled iid from $\mathcal{N}(0, 1)$.
3. The initial scalars c^0 converge almost surely to 0.
4. All functions ψ used in **OUTERNONLIN** are pseudo-Lipschitz.

2.4 宽度扩展 μ P 的 Tensor Program 理论——架构范畴

- 网络前传到 final feature 的过程能由如下三个算子表示，如 Transformer:

Avg We can choose an existing vector $\mathbf{x} \in \mathbb{R}^n$ and append to the program a scalar

$$\frac{1}{n} \sum_{\alpha=1}^n x_{\alpha} \in \mathbb{R}.$$

MatMul We can choose a matrix $\mathbf{W} \in \mathbb{R}^{n \times n}$ and vector $\mathbf{x} \in \mathbb{R}^n$ existing in the program, and append to the program a vector

$$\mathbf{W}\mathbf{x} \in \mathbb{R}^n \quad \text{or} \quad \mathbf{W}^{\top}\mathbf{x} \in \mathbb{R}^n.$$

OuterNonlin For any integer $k, l \geq 0$, we can aggregate k existing vectors and l existing scalars to $\mathbf{X} \in \mathbb{R}^{n \times k}$ and $\mathbf{c} \in \mathbb{R}^l$, respectively. With an integer $r \geq 0$ and a pseudo-Lipschitz function $\psi : \mathbb{R}^{k(r+1)+l} \rightarrow \mathbb{R}$ (e.g., SiLU, GeLU), we append to the program a vector

$$\mathbf{y} \in \mathbb{R}^n, \quad y_{\alpha} = \frac{1}{n^r} \sum_{\beta_1, \dots, \beta_r=1}^n \psi(\mathbf{X}_{\alpha,:}; \mathbf{X}_{\beta_1,:}; \dots; \mathbf{X}_{\beta_r,:}; \mathbf{c}^{\top}),$$

where the $r + 1$ is called the order of ψ .

2.4 宽度扩展 μ P 的 Tensor Program 理论——优化器范畴

- Tensor Program 理论能够考虑如下优化器集合：
 - $w_t^i = w_{t-1}^i - \eta Q_t(g_0^i, \dots, g_t^i)$, 其中 i 为参数的维度 index, g 为梯度
 - 经典的 SGD、Adam、Lion 等优化器均满足
 - 现代的矩阵预条件优化器如 Muon 等不满足

$$Q_t(g_0, \dots, g_t) = \frac{\frac{1}{1-\beta_1^{t+1}} \sum_{s=0}^t (1-\beta_1) \beta_1^{t-s} g_s}{\sqrt{\frac{1}{1-\beta_2^{t+1}} \sum_{s=0}^t (1-\beta_2) \beta_2^{t-s} g_s^2 + \epsilon^2}}, \quad (\text{Adam})$$






2.5 宽度扩展 μP 的 Diffusion Transformer 应用——研究问题

- 严谨的 μP 理论仅对 Tensor Program 可表示的架构成立，该结果对 diffusion Transformer 是否成立仍然未知
- 超参迁移性只在语言模型的场景下被验证，视觉生成任务是否成立未知
- μP 能够给 diffusion Transformers 带来多大的赋能未知


2.5 宽度扩展 μP 的 Diffusion Transformer 应用——理论结果

- U-ViT, DiT, PixArt, MM-DiT 等主流扩散模型架构可以被 Tensor Program 表示, 所以 AdamW 训练时的 μP 结论保持不变




2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——方法

- 实现和原来一致的 μ P 参数化，并进行超参迁移实验




(a) Implementation of DiT- μ P.




(b) μ Transfer.

2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——DiT


- 通过 DiT 在 ImageNet 上的图像生成实验验证了超参数的迁移性
 - 默认宽度 288 (43M) , bs 256, iter 200K (40 epochs)
 - Overfitting/多轮训练场景的最优学习率趋向于稳定边缘



(a) HP transfer across widths.




(b) HP transfer across batch sizes.



(c) HP transfer across iterations.

2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——DiT

- DiT 43M 搜索的学习率迁移到 675M，相较于基线取得了 **2.9 倍的加速**
 - 宽度扩大约 **4 倍**，训练步数扩大 **12 倍** 实现稳定高效训练
 - 反思：大幅的加速应该是来自于扩大 iter 没有减小学习率




2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——PixArt

- 搜超参场景：模型 39M，batch size 176x8，训练步数 39K（5 epoch）
- 预训练场景：模型 677M，batch size 176x32，训练步数 59K（30 epoch）
- 5 次搜索的 FLOPs 为一次预训练的 5.5%，训练结果一致超过基线


Epoch	Method	GenEval $\uparrow$	MJHQ		MS-COCO	
			FID-30K $\downarrow$	CLIP Score $\uparrow$	FID-30K $\downarrow$	CLIP Score $\uparrow$
10	PixArt- α [8]	0.19	38.36	25.78	34.58	28.12
	PixArt- α - μ P (Ours)	0.20	33.35	26.25	29.68	28.87
20	PixArt- α [8]	0.20	35.68	26.54	30.13	28.81
	PixArt- α - μ P (Ours)	0.23	33.42	26.83	29.05	29.53
30	PixArt- α [8]	0.15	42.71	26.25	37.61	28.91
	PixArt- α - μ P (Ours)	0.26	29.96	27.13	25.84	29.58

2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——MMDiT 18B


- 搜超参场景：模型 0.18B，batch size 4096，训练步数 30K（1/6 epoch）
 - 选最好的 5 组跑了 100K 步，验证超参随 iter 的迁移性。学习率 U-shape
 - 80 次搜索的 FLOPs 为一次预训练的 14.5%，大概是专家的 3%
- 预训练场景：模型 18B，batch size 4096，训练步数 200K




(a) Base learning rate.



(b) Base gradient clip.



(c) Base REPA loss weight.



(d) Base Warm-up steps.

2.5 宽度扩展 μ P 的 Diffusion Transformer 应用——MMDiT 18B

- 18B 的预训练实验中机评和人工评测均超过基线

Table 4 GenEval results of pretrained MMDiT-18B and MMDiT- μ P-18B models. MMDiT- μ P-18B achieves better benchmark results with only 3% of the manual tuning cost.

Method	Overall $\uparrow$	Single	Two	Counting	Colors	Position	Color Attribution
MMDiT-18B	0.8154	99.38	93.69	81.88	88.03	57.5	68.75
MMDiT- μ P-18B	0.8218	99.38	94.44	79.69	88.83	62.25	68.5




Figure 6 MMDiT- μ P-18B achieves consistently lower training loss than baseline after 15K steps.

Table 5 Results of human evaluation for text-image alignment. The alignment accuracy (acc.) is computed as the average over 22,500 human alignment tests. MMDiT- μ P-18B achieves superior results with only 3% of the manual tuning cost.

Method	Alignment acc. $\uparrow$
MMDiT-18B	0.703
MMDiT- μ P-18B (Ours)	0.715



内容纲要

- μP 的背景与影响
- 宽度扩展的 μP 理论与实践
- 宽深联合扩展的 μP 理论与实践
- 总结与展望



2.1 宽深联合 μ P 的前期研究

- 从 DiT- μ P 的工作可以看出来宽度扩展的 μ P 理论已经非常成熟！
- 前期的宽深联合 μ P 研究仍然很初步，呈现如下特征
 - 架构不同： $h_{l+1} = h_l + \alpha_l F_l(h_l)$ ，考虑的残差块 $F_l(h_l)$ 不同
 - 优化器特定：特定为 SGD 或者 Adam
 - 理论推导复杂：多基于 Tensor Program、DMFT 或者梯度分析
 - 结果各不相同：不同情形的结论不同
- 不利于社区的理解与进一步推广


2.1 宽深联合 μ P 的前期研究——Depth- μ P

- Depth- μ P 考虑单层残差块: $F_l(h_l) = W_l \phi(h_l)$, 优化器为 SGD/Adam
- Depth- μ P 结论: 在实现宽度 μ P 的前提下, $\alpha_l = \Theta\left(\frac{1}{\sqrt{L}}\right)$, 学习率对应调整:
能够实现深度 μ P 原则, 且最大化特征多样性

	Branch Multiplier	Learning Rate
Standard	1	? (tuned)
Depth- μ P (SGD)	$a/\sqrt{\text{depth}}$	η
Depth- μ P (Adam)	$a/\sqrt{\text{depth}}$	$\eta/\sqrt{\text{depth}}$

2.1 宽深联合 μ P 的前期研究——Depth- μ P

- Depth- μ P 在实际网络（多层残差块）训练中难以实现稳定深度超参迁移




2.1 宽深联合 μ P 的前期研究——CompleteP

- CompleteP 考虑 **两层残差块**: $F_l(h_l) = W_l^{(2)}W_l^{(1)}h_l$, 优化器为 AdamW
- CompleteP 结论: 在实现宽度 μ P 的前提下, 额外引入 $\alpha_l = \Theta(\frac{1}{L})$

	Input weights & biases	Hidden weights	Output weights	Hidden biases
Block Multiplier	α_{base}	α_{base}/r_L (α_{base})	α_{base}/r_n (α_{base})	α_{base}/r_L (α_{base})
Initial Variance	$\sigma_{\text{base}}^2/d_0$ or σ_{base}^2	$\sigma_{\text{base}}^2/r_n$ (σ_{base}^2)	σ_{base}^2	σ_{base}^2
Learning Rate	η_{base}	η_{base}/r_n (η_{base})	η_{base}	η_{base}
Weight Decay	λ_{base}	$\lambda_{\text{base}}r_n$ (λ_{base})	λ_{base}	λ_{base}
AdamW ε	$\varepsilon_{\text{base}}/r_n$ ($\varepsilon_{\text{base}}$)	$\varepsilon_{\text{base}}/(r_L r_n)$ ($\varepsilon_{\text{base}}$)	$\varepsilon_{\text{base}}/r_n$ ($\varepsilon_{\text{base}}$)	$\varepsilon_{\text{base}}/(r_L r_n)$ ($\varepsilon_{\text{base}}$)

2.1 宽深联合 μP 的前期研究——CompleteP

- CompleteP 在实际 GPT-2 的 AdamW 训练中能够实现稳定的深度超参迁移



Don't be lazy: CompleteP enables compute-efficient deep transformers, NeurIPS, 2025

2.2 宽深联合 μP 的谱条件理论——理论原型

- 相较于宽度扩展场景的 μP 谱条件理论，理论原型有如下改进
 - **原型改进 1**：残差连接为深度扩展的必备结构，因此引入残差连接
 - **原型改进 2**：残差块通常有两层以上，因此考虑任意有限 k 层残差块

最简原型结构：残差块为两层的 deep linear MLP

$$\begin{aligned}h_0 &= \alpha_0 W_0 x \\h_l &= h_{l-1} + \alpha_l \prod W_l^{(i)} h_{l-1}, \forall l \in [L] \\h_{L+1} &= \alpha_{L+1} W_{L+1} h_L\end{aligned}$$

后续我们将表明，**两层残差块 ($k = 2$)** 是能够反映真实情况的最简模型。

2.2 宽深联合 μP 的谱条件理论—单层残差块 ($k = 1$)

- 单层残差块时的理论结果:

初始化条件:

- 输入和输出层: $\alpha_0 \|W_0\|_{RMS}, \alpha_{L+1} \|W_{L+1}\|_{RMS} = \Theta(1)$
- 隐藏层: $\alpha_l \|W_l\|_{RMS} = O\left(\frac{1}{\sqrt{L}}\right), \forall l \in [L]$

更新条件:

- 输入和输出层: $\alpha_0 \|\Delta W_0\|_{RMS}, \alpha_{L+1} \|\Delta W_{L+1}\|_{RMS} = \Theta(1)$
- 隐藏层一阶条件: $\alpha_l \|\Delta W_l\|_{RMS} = \Theta\left(\frac{1}{L}\right), \forall l \in [L]$

- 基于宽度 μP 的实现有 $\|W_l\|_{RMS} = \Theta(1)$, 所以得到 $\alpha_l = O(1/\sqrt{L})$ 。

2.2 宽深联合 μP 的谱条件理论—单层残差块 ($k = 1$)

- $\alpha_l = O(1/\sqrt{L})$, 调整学习率能够让一阶更新量 ϵ_1 满足 μP 条件为 $\Theta(1)$
- $\alpha_l = \Theta(1/\sqrt{L})$ 能够额外让零阶更新量 ϵ_0 也最大化为 $\Theta(1)$
 - 与 Depth- μP 原论文最大化特征多样性对应
- Depth- μP 的其它超参（如学习率）参数化都能被推导出来

$$\Delta \mathbf{h}_s(\mathbf{x}) = \Delta \mathbf{h}_0(\mathbf{x}) + \underbrace{\sum_{l=1}^s \alpha_l \mathbf{W}_l \Delta \mathbf{h}_{l-1}(\mathbf{x})}_{\epsilon_0(s)} + \underbrace{\sum_{l=1}^s \alpha_l \Delta \mathbf{W}_l (\mathbf{h}_{l-1}(\mathbf{x}) + \Delta \mathbf{h}_{l-1}(\mathbf{x}))}_{\epsilon_1(s)}.$$

2.2 宽深联合 μP 的谱条件理论—双层残差块 ($k = 2$)

- 双层残差块时的理论结果:

初始化条件:

- 输入和输出层: $\alpha_0 \|W_0\|_{RMS}, \alpha_{L+1} \|W_{L+1}\|_{RMS} = \Theta(1)$
- 隐藏层: $\alpha_l \|W_l^{(2)}\|_{RMS} \|W_l^{(1)}\|_{RMS} = \Theta\left(\frac{1}{L}\right), \forall l \in [L]$ (二阶更新条件造成)

更新条件:

- 输入和输出层: $\alpha_0 \|\Delta W_0\|_{RMS}, \alpha_{L+1} \|\Delta W_{L+1}\|_{RMS} = \Theta(1)$
- 隐藏层一阶条件 1: $\alpha_l \|\Delta W_l^{(2)}\|_{RMS} \|W_l^{(1)}\|_{RMS} = \Theta\left(\frac{1}{L}\right), \forall l \in [L]$
- 隐藏层一阶条件 2: $\alpha_l \|W_l^{(2)}\|_{RMS} \|\Delta W_l^{(1)}\|_{RMS} = \Theta\left(\frac{1}{L}\right), \forall l \in [L]$
- 隐藏层二阶条件: $\alpha_l \|\Delta W_l^{(2)}\|_{RMS} \|\Delta W_l^{(1)}\|_{RMS} = \Theta\left(\frac{1}{L}\right), \forall l \in [L]$

- 基于宽度 μP 的实现有 $\|W_l\|_{RMS} = \Theta(1)$, 得到 $\alpha_l = O(1/L)$, 与 CompleteP 一致

2.2 宽深联合 μP 的谱条件理论—双层残差块 ($k = 2$)

- 双层残差块相较于单层的本质区别：高阶更新量的出现
 - 令 $\epsilon_2 = \Theta(1)$ 得到二阶更新条件，并反馈得到更紧的初始化条件
 - 更深的残差块不会影响最终结果，双层残差块为最简理论原型

$$\begin{aligned}
 \Delta \mathbf{h}_s(\mathbf{x}) = & \Delta \mathbf{h}_0(\mathbf{x}) + \underbrace{\sum_{l=1}^s \alpha_l \mathbf{W}_l^{(2)} \mathbf{W}_l^{(1)} \Delta \mathbf{h}_{l-1}(\mathbf{x})}_{\epsilon_0(s)} + \underbrace{\sum_{l=1}^s \alpha_l \mathbf{W}_l^{(2)} \Delta \mathbf{W}_l^{(1)} (\mathbf{h}_{l-1}(\mathbf{x}) + \Delta \mathbf{h}_{l-1}(\mathbf{x}))}_{\epsilon_1^{(1)}(s)} \\
 & + \underbrace{\sum_{l=1}^s \alpha_l \Delta \mathbf{W}_l^{(2)} \mathbf{W}_l^{(1)} (\mathbf{h}_{l-1}(\mathbf{x}) + \Delta \mathbf{h}_{l-1}(\mathbf{x}))}_{\epsilon_1^{(2)}(s)} + \underbrace{\sum_{l=1}^s \alpha_l \Delta \mathbf{W}_l^{(2)} \Delta \mathbf{W}_l^{(1)} (\mathbf{h}_{l-1}(\mathbf{x}) + \Delta \mathbf{h}_{l-1}(\mathbf{x}))}_{\epsilon_2(s)}.
 \end{aligned}$$

2.3 宽深联合 μP 的算法 ($k \geq 2$)——实现


- 对于主流优化器（Muon-Kimi, Muon, Shampoo, SOAP, AdamW, Sophia, Lion, SSO 等），基于宽度 μP 实现，额外加入 $\alpha_l = \Theta(1/L)$ 即可

Table 2: μP implementation for Muon-Kimi (Liu et al., 2025) with weight decay under width-depth scaling. Entries in **purple** indicate differences between μP and SP, while **gray** shows the corresponding SP choices. Here, r_n and r_L denote the width and depth scaling ratios relative to the base model. The variance of input weights is σ_{base}^2 for language and $\sigma_{\text{base}}^2/d_0$ for image.

	Input weights	Hidden weights	Output weights
Block Multiplier	α_{base}	α_{base}/r_L (α_{base})	α_{base}/r_n (α_{base})
Initial Variance	$\sigma_{\text{base}}^2/d_0$ or σ_{base}^2	$\sigma_{\text{base}}^2/r_n$ (σ_{base}^2)	σ_{base}^2
Learning Rate	η_{base}	$\eta_{\text{base}}/\sqrt{r_n}$ (η_{base})	η_{base}
Weight Decay	λ_{base}	$\lambda_{\text{base}}\sqrt{r_n}$ (λ_{base})	λ_{base}


2.3 宽深联合 μP 的算法 ($k \geq 2$)——Muon-Kimi-AdamW 效果

- μP ($k \geq 2$) 能够实现宽深扩展时的训练稳定和超参迁移




2.3 宽深联合 μP 的算法 ($k \geq 2$)——Muon-AdamW 效果

- μP ($k \geq 2$) 能够实现宽深扩展时的更好的训练稳定和超参迁移




2.3 宽深联合 μP 的算法 ($k \geq 2$)——Shampoo-AdamW 效果

- μP ($k \geq 2$) 能够实现宽深扩展时的更好的训练稳定和超参迁移




2.3 宽深联合 μP 的算法 ($k \geq 2$)——Sophia 效果

- μP ($k \geq 2$) 能够实现宽深扩展时的更好的训练稳定和超参迁移




2.4 μP ($k \geq 2$) 优于 μP ($k \geq 1$)——Muon-Kimi-AdamW 效果

- μP ($k \geq 2$) 能够实现深度扩展时的更好的超参迁移




2.4 μP ($k \geq 2$) 优于 μP ($k \geq 1$)——Muon-AdamW 效果

- μP ($k \geq 2$) 能够实现深度扩展时的更好的超参迁移




2.4 μP ($k \geq 2$) 优于 μP ($k \geq 1$)——Shampoo-AdamW 效果

- μP ($k \geq 2$) 能够实现深度扩展时的更好的超参迁移



2.4 μP ($k \geq 2$) 优于 μP ($k \geq 1$)——Sophia 效果

- μP ($k \geq 2$) 能够实现深度扩展时的更好的超参迁移





内容纲要

- μP 的背景与影响
- 宽度扩展的 μP 理论与实践
- 宽深联合扩展的 μP 理论与实践
- 总结与展望

总结与展望

- TP 假设下：
 - 实践上，中小规模训练场景的超参宽深迁移基本被解决
 - 理论上， μP 参数化的超参迁移性质仍然是个谜（norm 的选择）
- 不满足 TP 假设的维度：数据量、数据维度等
- 其它未被充分考虑的 scaling 维度：数据量、稀疏度等

总结与展望

- 原则上， μP 思想可以指导架构和优化器设计，而非停留在超参迁移
 - 一阶最速实现每一步 $\|\Delta h_l\|_{RMS} = \Theta(1)$: Muon
 - 一阶最速实现每一步 $\|h_l\|_{RMS} = \Theta(1), \|\Delta h_l\|_{RMS} = \Theta(1)$: SSO, Hyperball
 - 选择更合适的范数衡量特征: Scion, MOGA

设 $h_l \in R^{n_l}$ 为第 l 层的特征， $\Delta h_l \in R^{n_l}$ 为其经过一步优化的更新量， μP 希望：

$$\|h_l\|_{RMS} = \Theta(1), \|\Delta h_l\|_{RMS} = \Theta(1), \quad l \in [L]$$

$$\text{maximize } \Delta W'_l \text{'s contribution to } \Delta h_L, \quad l \in [L]$$