

Optimizer Design based on μ P Principle

郑晨宇





内容纲要

- μP 原则启发的优化器框架
- μP 更新原则的信赖域实现
- μP 参数原则的可行域实现
- 总结与展望



1.1 优化基础概览——优化问题

- 变量/参数 x : 我们想要优化的对象
- 目标函数 $f(x)$: 我们想要优化的目标
- 可行域 X : 变量的可取范围/约束范围

$$\min_x f(x) \quad s.t. \ x \in X$$



1.1 优化基础概览——优化算法

- 直接求解最优点困难，常采用**迭代式**优化算法
- 优化算法的目标：在每一步找到好的**方向和步长**
 - 线搜索方法：先定方向，再选/搜索步长
 - **信赖域方法（今天的主题）**：先定步长/邻域，再选方向
- 信赖域方法，假设现在走到了 x^k ：
 - 确定步长/邻域 η ： $\|x - x^k\| \leq \eta$ ，依赖于 lr schedule
 - 在邻域内**基于信息设计代理函数**来近似目标函数： $m(x^k, x) \approx f(x)$
 - 在邻域内**最小化代理函数** $\min m(x^k, x) \text{ s.t. } \|x - x^k\| \leq \eta$



1.1 优化基础概览——最速下降（最简信赖域一阶算法）

- 确定步长/邻域 η : $\|x - x^k\| \leq \eta$
- 代理函数为一阶泰勒展开
 - $m(x^k, x) = f(x^k) + \langle \nabla f(x^k), x - x^k \rangle$
- 在邻域内最小化代理函数
 - $\min_x m(x^k, x) = \min_x \langle \nabla f(x^k), x - x^k \rangle, \text{ s.t. } \|x - x^k\| \leq \eta$
 - 等价于 $\min_d \langle \nabla f(x^k), d \rangle, \text{ s.t. } \|d\| \leq \eta$



1.1 优化基础概览——最速下降（最简信赖域一阶算法）

- $$\operatorname{argmin}_{\|d\| \leq \eta} \langle \nabla f(x^k), d \rangle = \eta \operatorname{argmin}_{\|t\| \leq 1} \langle \nabla f(x^k), t \rangle = -\eta \operatorname{argmax}_{\|t\| \leq 1} -\langle \nabla f(x^k), t \rangle$$
$$= -\eta \operatorname{argmax}_{\|u\| \leq 1} \langle \nabla f(x^k), u \rangle$$
- $\langle \nabla f(x^k), u \rangle \leq \|\nabla f(x^k)\|_* \|u\| = \|\nabla f(x^k)\|_*$, u 为取得对偶范数的方向
- 当 $\|\cdot\| = \|\cdot\|_2$, $d = -\eta \frac{\nabla f(x^k)}{\|\nabla f(x^k)\|_2}$, 为标准梯度下降
- 当 $\|\cdot\| = \|\cdot\|_\infty$, $d = -\eta \operatorname{sign}(\nabla f(x^k))$, 为 SignGD（无动量的 Adam）

1.2 μ P 基础概览——又稳又快原则

- μ P 原则上希望在特征变动量级和网络规模无关（稳定）的前提下尽可能更新权重（高效）。否则，特征随网络变大趋于爆炸或者冻结。

设 $h_l \in R^{n_l}$ 为第 l 层的特征， $\Delta h_l \in R^{n_l}$ 为其经过一步优化的更新量， μ P 希望：

$$\|h_l\|_{RMS} = \Theta(1), \|\Delta h_l\|_{RMS} = \Theta(1), \quad l \in [L]$$

$$\text{maximize } \Delta W'_l \text{'s contribution to } \Delta h_L, \quad l \in [L]$$

其中 $\|v\|_{RMS} = \frac{\|v\|_2}{\sqrt{d}} = \sqrt{\frac{\sum v_i^2}{d}}$ ，衡量是特征向量每个维度的平均大小。



1.2 μ P 基础概览——宽度扩展的谱条件

- 为了满足宽度扩展时的 μ P 原则，可令参数及其更新量满足以下：
 - 若输入的 RMS 范数稳定，则输出的 RMS 范数也稳定

设 $W_l \in R^{n_l \times n_{l-1}}$ 为第 l 层的权重， $\Delta W_l \in R^{n_l \times n_{l-1}}$ 为其经过一步优化的变动，需要：

$$\|W_l\|_{RMS} = \Theta(1), \|\Delta W_l\|_{RMS} = \Theta(1), l \in [L]$$

$$\text{其中 } \|W\|_{RMS} = \sup_{x \neq 0} \frac{\|Wx\|_{RMS}}{\|x\|_{RMS}} = \sqrt{\frac{n_{l-1}}{n_l}} \|W\|_2。$$



1.3 μP 启发的优化器框架

- 定理形式确定矩阵定义域: $\min_W f(W)$
- 参数谱条件确定可行域: $\min_W f(W) \quad \text{s.t.} \quad \|W\|_{RMS} = c$
- 更新谱条件确定信赖域: $\|\Delta W\|_{RMS} \leq \eta$
- 近似函数设计上基本为一阶展开 $\min_{\Delta W} \langle \nabla f(W^k), \Delta W \rangle, \quad \text{s.t.} \quad \|\Delta W\|_{RMS} \leq \eta$

Open Q: 能否用最速下降以外的近似函数? 如二阶展开

Open Q: 能否将思想融入信赖域以外的优化框架?



内容纲要

- μP 原则启发的优化器框架
- μP 更新原则的信赖域实现
- μP 参数原则的可行域实现
- 总结与展望

2.1 μP 更新原则的信赖域实现（最速下降）

- 定理形式确定矩阵定义域: $\min_W f(W)$
- 参数谱条件确定可行域: $\min_W f(W) \quad s.t. \quad \|W\|_{RMS} = c$
- 更新谱条件确定信赖域: $\|\Delta W\|_{RMS} \leq \eta$
- 近似函数设计上基本为一阶展开 $\min_{\Delta W} \langle \nabla f(W^k), \Delta W \rangle, \quad s.t. \quad \|\Delta W\|_{RMS} \leq \eta$

在训练初期能够实现 μP 原则 $\|W\|_{RMS} = \Theta(1)$



2.1 μP 更新原则的最速下降解——Muon

- $\operatorname{argmin}_{\|\Delta W\| \leq \eta} \langle \nabla f(W^k), \Delta W \rangle = \eta \operatorname{argmin}_{\|\Delta T\| \leq 1} \langle \nabla f(W^k), \Delta T \rangle = -\eta \operatorname{argmax}_{\|\Delta U\| \leq 1} \langle \nabla f(W^k), \Delta U \rangle$
- $\langle \nabla f(W^k), \Delta U \rangle \leq \|\nabla f(W^k)\|_* \|\Delta U\| = \|\nabla f(W^k)\|_*$, ΔU 为取得对偶范数方向
- 当 $\|\cdot\| = \|\cdot\|_{RMS}$, $\Delta W = -\eta \sqrt{\frac{n_{out}}{n_{in}}} \operatorname{Msign}(\nabla f(W^k))$
 - 其中 $\nabla f(W^k) = U\Sigma V^\top$, $\operatorname{Msign}(\nabla f(W^k)) = UV^\top$, 将梯度各个特征方向更新幅度拉平
- 这正是 Muon 优化器（稳定打败 AdamW 基线）

2.2 广义 μ P 更新原则的信赖域实现 (最速下降)

- 定理形式确定矩阵定义域: $\min_W f(W)$
- 参数谱条件确定可行域: $\min_W f(W) \quad s.t. \quad \|W\|_{RMS} = c$
- 更新谱条件确定信赖域: $\|\Delta W\| \leq \eta$
- 近似函数设计上基本为一阶展开 $\min_{\Delta W} \langle \nabla f(W^k), \Delta W \rangle, \quad s.t. \quad \|\Delta W\|_{RMS} \leq \eta$

不限定 $\|\Delta W\|_{RMS}$, 而是根据各层特征性质选择

2.2 广义 μP 更新原则的最速下降解——Scion

- Muon + Adam: 隐藏层 $\|\Delta W\|_{RMS}$, 输入输出层 $\|\Delta W\|_{1 \rightarrow \infty}$
- **Scion**: 隐藏层 $\|\Delta W\|_{RMS}$, 输入层 $\|\Delta W\|_{1 \rightarrow RMS}$, 输出层 $\|\Delta W\|_{1 \rightarrow \infty}$

Table 3. The choice of lmo can be different between layers and can depend on the assumptions on the input. For simplicity we overload notation and write the reduced SVD as $W_\ell = U \text{diag}(\sigma) V^\top \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ for all $\ell \in [L]$.


Parameter	W_1 (image domain)	$\{W_\ell\}_{\ell \in [2, \dots, L-1]}$	W_L			b_ℓ
Norm	RMS $\rightarrow$ RMS	RMS $\rightarrow$ RMS	RMS $\rightarrow$ RMS	RMS $\rightarrow \infty$	$1 \rightarrow \infty$	RMS
LMO	$-\max(1, \sqrt{d_{\text{out}}/d_{\text{in}}})UV^\top$	$-\sqrt{d_{\text{out}}/d_{\text{in}}}UV^\top$	$-\sqrt{d_{\text{out}}/d_{\text{in}}}UV^\top$	$\text{row}_i(W_L) \mapsto -\frac{1}{\sqrt{d_{\text{in}}}} \frac{\text{row}_i(W_L)}{\ \text{row}_i(W_L)\ _2}$	$-\frac{1}{d_{\text{in}}} \text{sign}(W_L)$	$-\frac{b_\ell}{\ b_\ell\ _{\text{RMS}}}$
Init.	Semi-orthogonal	Semi-orthogonal	Semi-orthogonal	Row-wise normalized Gaussian	Random sign	0

Table 4. Example lmo choices for 1-hot encoded inputs.

Parameter	W_1 (1-hot encoded input)		
Norm	$2 \rightarrow \text{RMS}$	$1 \rightarrow \text{RMS}$	$1 \rightarrow \infty$
LMO	$-\sqrt{d_{\text{out}}}UV^\top$	$\text{col}_j(W_1) \mapsto -\sqrt{d_{\text{out}}} \frac{\text{col}_j(W_1)}{\ \text{col}_j(W_1)\ _2}$	$-\text{sign}(W_1)$
Init.	Semi-orthogonal	Column-wise normalized Gaussian	Random sign

2.2 广义 μP 更新原则的最速下降解——Scion

- Open Q: 各层的最优范数分别是什么？超参迁移的条件是什么？






2.3 只考虑 μP 更新原则的问题

- 长时间训练 ($K \gg n$) 可能破坏 μP 参数原则
- $\|W^K\|_{RMS} = \|W^0 + \sum \Delta W^k\| \leq \|W_0\|_{RMS} + \sum \|\Delta W^k\| = \Theta(K) \neq \Theta(1)$
- 朴素（隐式）的解决方法是引入 independent weight decay


2.3 只考虑 μP 更新原则的问题——训练稳定性/效果

- 引入 iwd 能够显著提升长程训练的稳定性/效果



2.3 只考虑 μP 更新原则的问题——超参迁移

- 引入 iwd 能够显著提升长程训练的超参迁移性，超参迁移条件是什么？





2.3 只考虑 μP 更新原则的问题

- Q: iwd 在长程训练中究竟能起哪些作用？
- Q: 如果引入 iwd 只是为了实现参数原则，为什么不直接实现参数原则呢？



内容纲要

- μP 原则启发的优化器框架
- μP 更新原则的信赖域实现
- μP 参数原则的可行域实现
- 总结与展望



3.1 μ P 参数原则的可行域实现 (流形最速下降)

- 定理形式确定矩阵定义域: $\min_W f(W)$
- 参数谱条件确定可行域: $\min_W f(W) \quad \text{s.t.} \quad \|W\|_{RMS} = c$
- 更新谱条件确定信赖域: $\|\Delta W\|_{RMS} \leq \eta$
- 一阶近似 $\min_{\Delta W} \langle \nabla f(W^k), \Delta W \rangle$
 - s.t. $\|\Delta W\|_{RMS} \leq \eta, \|W^k\|_{RMS} = c, \|W^k + \Delta W\|_{RMS} = c$

在训练的任何时期都能够实现 μ P 原则

3.2 μ P 参数原则的流形最速下降解——SSO

- $\min_{\Delta W} \langle \nabla f(W^k), \Delta W \rangle, \text{ s.t. } \|\Delta W\|_{RMS} \leq \eta, \|W^k\|_{RMS} = c, \|W^k + \Delta W\|_{RMS} = c$
- $\max_{\Delta T} \langle \nabla f(W^k), \Delta T \rangle, \text{ s.t. } \|\Delta T\|_{RMS} \leq 1, \|W^k\|_{RMS} = c, \|W^k - \eta \Delta T\|_{RMS} = c$
- $\max_{\Delta U} \langle \nabla f(W^k), \Delta U \rangle, \text{ s.t. } \|\Delta U\|_2 \leq 1, \|W^k\|_2 = cR, \|W^k - \eta R \Delta U\|_2 = cR$
 - $R = \sqrt{n_{out}/n_{in}}$

3.2 μP 参数原则的流形最速下降解——SSO

- $\max_{\Delta U} \langle \nabla f(W^k), \Delta U \rangle, \text{ s.t. } \|\Delta U\|_2 \leq 1, \|W^k\|_2 = cR, \|W^k - \eta R \Delta U\|_2 = cR$
- $\nabla \|W\|_2 = u_1 v_1^\top$, 其中 u_1, v_1 为最大奇异值对应的向量
- $\|W - \eta R \Delta U\|_2 = \|W\|_2 + \langle u_1 v_1^\top, -\eta R \Delta U \rangle + O(\eta^2) \approx \|W\|_2 - \eta R \langle u_1 v_1^\top, \Delta U \rangle$
- 由 $\|W^k\|_2 = cR, \|W - \eta R \Delta U\|_2 = cR$, 可得 $\langle u_1 v_1^\top, \Delta U \rangle = 0$
 - 即更新量与当前参数的秩 1 近似矩阵正交
- $\max_{\Delta U} \langle \nabla f(W^k), \Delta U \rangle, \text{ s.t. } \|\Delta U\|_2 \leq 1, \langle u_1 v_1^\top, \Delta U \rangle = 0$



3.2 μ P 参数原则的流形最速下降解——SSO

- $\max_{\Delta U} \langle \nabla f(W^k), \Delta U \rangle, \text{ s.t. } \|\Delta U\|_2 \leq 1, \langle u_1 v_1^\top, \Delta U \rangle = 0$
- 拉格朗日函数 $\langle \nabla f(W^k) + \lambda u_1 v_1^\top, \Delta U \rangle \leq \|\nabla f(W^k) + \lambda u_1 v_1^\top\|_*$
- ΔU 取得对偶范数方向时最大, $\Delta U = \text{Msign}(\nabla f(W^k) + \lambda u_1 v_1^\top)$
- 且 λ 满足约束 $\langle u_1 v_1^\top, \text{Msign}(\nabla f(W^k) + \lambda u_1 v_1^\top) \rangle = 0$, 可用二分法求解
- 由于约束用了一阶近似, 所以还需要投影 $W^{k+1} = cR \frac{W^k - cR\Delta U}{\|W^k - cR\Delta U\|_2}$

Open Q: 其它范数的流形最速下降实现?

3.2 μP 参数原则的流形最速下降解——SSO




Figure 4: **Geometry of Steepest Descent Update Directions.** The left solid arc denotes the W sphere, while the right dotted arc denotes the ΔW sphere (unit Φ scaled by η). The shaded region represents the feasible set within the *tangent space* of the W sphere at step W_i . Under weight constraint, projecting G onto the tangent space (**Spectral Sphere**) yields the largest update angle.

3.2 μ P 参数原则的流形最速下降解——SSO

- SSO 的性能效果比较好





Figure 8: Validation loss of training dense 1.7B model on 100B tokens. As a reference point,

3.2 μP 参数原则的流形最速下降解——SSO


- SSO 的超参迁移性比 Muon 好（和 iwd 一样）



3.3 Hyperball: 更轻量的球面优化器


- 谱范数相关的切空间、Msign 和投影计算复杂度较高，换成 F 范数也挺好

$$W_{t+1} = R \cdot \text{Normalize}\left(\left(W_t - \eta_t R \cdot \text{Normalize}(u_t)\right)\right).$$




3.3 Hyperball: 更轻量的球面优化器

- 比普通 Muon 好，但和 SSO 比较未知



3.3 Hyperball: 更轻量的球面优化器

- 超参迁移性也比基线更好，但看起来不如 SSO





内容纲要

- μP 原则启发的优化器框架
- μP 更新原则的信赖域实现
- μP 参数原则的可行域实现
- 总结与展望



总结与展望

- μP 条件本身还需要结合实际，获得更深的理解
- μP 条件的更深理解将进一步促进优化器和架构的发展